

CENTRO DE ENSEÑANZA TÉCNICA Y SUPERIOR



Proyecto:
Extendiendo el Modelo Multidimensional

Materia:
Aplicaciones para minería de datos

Profesor:
Miguel Gonzalez Marquez

Estudiante:
Andrés Silva López e012752

Ensenada, B.C , a 22 de septiembre de 2026

Los modelos multidimensionales permiten representar información compleja mediante vectores, matrices y tensores, facilitando su procesamiento en algoritmos de aprendizaje automático. Sin embargo, la transformación de datos como imágenes y texto a espacios numéricos genera retos relacionados con el aumento de dimensiones, la representación de características y el cálculo de distancias.

El espacio vectorial de las imágenes

Una imagen RGB de 256 x 256 píxeles se representa como un tensor de tres dimensiones, donde cada eje corresponde a la altura, el ancho y los canales de color. Cada elemento del tensor almacena la intensidad de un canal específico en un píxel.

Desde la perspectiva de un modelo de aprendizaje automático, la imagen puede transformarse en un vector de características mediante un proceso de aplanamiento. En este caso, el tensor se convierte en una representación unidimensional con 196,608 valores, que corresponden a las características de entrada del modelo.

Tenemos que tener en cuenta que es importante distinguir entre las dimensiones del tensor y el número de características utilizado por el algoritmo. Las redes neuronales convolucionales suelen conservar la estructura espacial de la imagen para identificar patrones, mientras que otros modelos pueden trabajar con vectores aplanados.

El espacio vectorial del Texto (Word Embeddings / TF-IDF)

El Procesamiento de Lenguaje Natural transforma palabras y documentos en representaciones numéricas para permitir su análisis mediante operaciones matemáticas, como similitud y distancia.

Los Words Embeddings representan palabras como vectores dentro de un espacio de características continuas, estos vectores pueden capturar relaciones semánticas y sintácticas aprendidas a partir de grandes cantidades de texto.

El TF-IDF transforma documentos en vectores dispersos, donde cada dimensión representa un término del vocabulario y su valor indica la importancia relativa de dicho término en un documento, en comparación con los embeddings, el TF-IDF se basa en la frecuencia de las palabras y su distribución entre documentos, sin representar directamente relaciones semánticas complejas.

La maldición de la dimensionalidad

La maldición de la dimensionalidad describe los problemas estadísticos y computacionales asociados con el incremento del número de dimensiones en un espacio de datos, en el contexto

de algoritmos podemos basarlo en distancias como KNN, el aumento de características puede reducir la capacidad de distinguir entre observaciones cercanas y lejanas.

El volumen de los espacios multidimensionales aumenta rápidamente, provocando que los datos se encuentren más dispersos cuando el número de dimensiones crece. Bajo determinadas distribuciones, las distancias entre puntos pueden concentrarse, haciendo que las diferencias relativas entre vecinos cercanos y lejanos sean menos significativas.

Este fenómeno afecta la eficiencia de los algoritmos de búsqueda de vecinos y puede disminuir su capacidad para identificar patrones relevantes. Además, la presencia de características irrelevantes o redundantes puede incrementar el ruido en las distancias calculadas.

Referencias:

- *An Introduction to Statistical Learning*. (2021). An Introduction to Statistical Learning.
<https://www.statlearning.com>
- *TfidfTransformer*. (2026). Scikit-Learn.
https://scikit-learn.org/stable/modules/generated/sklearn.feature_extraction.text.TfidfTransformer.html
- JulCsc. (2026). *Modelos multidimensionales*. MicrosoftLearn.
<https://learn.microsoft.com/es-es/analysis-services/multidimensional-models/multidimensional-models-ssas?view=sql-analysis-services-2025>
- Ángel. (2023). *Base de datos multidimensionales: qué son y cuándo se usan* - Blog Incentro. Incentro. <https://www.incentro.com>